

Faro AI — Inteligência Competitiva + Retenção VIN Share

Relatório Técnico — Desafio 2

Segmentação Comportamental e Classificação Preditiva de Clientes Ford

Challenge: Ford × FIAP 2026 · 1ª Sprint

Data de entrega: 24/05/2026

Equipe (FIAP):

- Guilherme — RM 554962
- Pedro — RM 555556
- Fabrício — RM 558216
- Vitor — RM 554893
- Matheus — RM 555447

1. Sumário Executivo

Este relatório apresenta a solução analítica desenvolvida para o **Desafio 2** do Ford×FIAP Challenge 2026: aumentar a retenção de clientes na rede oficial de manutenção pós-venda da Ford. O projeto combina técnicas de aprendizado não-supervisionado (clustering) sobre o histórico completo de clientes (Base 1) com um classificador supervisionado (XGBoost) treinado exclusivamente sobre dados disponíveis no momento da compra (Base 2), garantindo zero data leakage.

A solução identifica **quatro perfis comportamentais** distintos — Cliente Fiel, Cliente Esquecido, Cliente Econômico e Cliente de Abandono — e permite, no ato da venda, prever a qual perfil o novo cliente provavelmente pertencerá. Para cada perfil são propostas ações de retenção específicas, executáveis pelo CRM da concessionária.

Upgrade: dados reais Ford BR. O modelo de produção (xgb-real-v1) foi treinado com **175.554** VINs reais do arquivo vin_share_Desafio_02.xlsx (140.443 treino · 35.111 teste). entregando **accuracy 62.7%** · F1-weighted 0.602 · F1-macro 0.482. As métricas no sintético (Seção 5) são mantidas como baseline histórico de desenvolvimento — todo o produto consulta o modelo real.

2. Hipótese de Negócio

A área de pós-venda da Ford parte da hipótese de que existem quatro arquétipos principais entre os compradores de veículos novos:

Perfil	Comportamento esperado
Fiel	Retorna consistentemente à rede oficial, independente de preço.
Abandono	Faz no máximo a primeira revisão e migra para oficinas externas.
Esquecido	Perde o timing da revisão; tenta voltar tarde e se frustra.
Econômico	Mantém vínculo mas é altamente sensível a preço/promoção.

Coube ao grupo **validar** se os dados sustentam essa estrutura via clustering não-supervisionado, sem assumir as classes a priori.

3. Bases de Dados

Durante o desenvolvimento inicial, usamos bases sintéticas geradas em services/ml/src/synthetic.py para validar todo o pipeline (EDA, clustering, treino, avaliação) sem depender da chegada do dataset oficial. **Na versão final em produção**, o modelo xgb-real-v1 foi treinado com a **base real Ford BR de 175.554 VINs** (vin_share_Desafio_02.xlsx) — descrito em detalhe na Seção 5.bis. As métricas sintéticas (Seção 5) são mantidas apenas como baseline histórico de desenvolvimento. As bases sintéticas seguiram a mesma estrutura conceitual Base 1 (histórico completo) e Base 2 (apenas dados pré-compra):

Base	Conteúdo	Uso
Base 1	Histórico completo (incluindo comportamento pós-compra: revisões realizadas, gasto, dias até última visita, churn)	Exclusivamente para clustering — define ground truth dos perfis
Base 2	Apenas variáveis disponíveis no ato da compra (demográficas, score, modelo, forma de pagamento, canal de aquisição, primeiro carro, test drive)	Treino do classificador supervisionado

Regra crítica observada: nenhuma variável que represente comportamento pós-compra (revisões realizadas, gasto acumulado, churn) entrou no classificador. A separação Base1/Base2 é implementada em `synthetic.split_base1_base2()` e a lista de features do classificador é fixa em `classifier.py`:

idade, genero, regioao, renda_mensal_brl, estado_civil, score_credito, modelo_comprado, versao_comprada, preco_pago_brl, financiamento, parcelas, canal_aquisicao, primeiro_carro, test_drive_realizado.

4. Pipeline Analítico

4.1 Preparação

EDA executada no notebook `services/ml/notebooks/ford_segmentation.ipynb` cobre: distribuições das variáveis, correlações, valores faltantes (zero, dado sintético controlado), boxplots por perfil-real e validação de cardinalidade das categóricas. As features numéricas são padronizadas (StandardScaler) e as categóricas são one-hot (OneHotEncoder com `handle_unknown='ignore'`) via ColumnTransformer.

4.2 Segmentação (Base 1)

Algoritmo: **K-Means** com $k=4$ escolhido por elbow method (SSE) e validado por *silhouette score*. Variáveis usadas: idade, renda, score, preço pago, parcelas, financiamento, canal de aquisição *combinadas com* variáveis comportamentais (revisões realizadas, dias até última manutenção, gasto acumulado, taxa de aderência ao plano).

Cluster	Persona	N clientes	% da base
0	Fiel	1503	18.8%
1	Abandono	3032	37.9%
3	Esquecido	1762	22.0%
2	Economico	1703	21.3%

Silhouette score: **0.290** (estrutura presente, separação razoável para dados socio-comportamentais reais).

4.3 Mapeamento Cluster → Persona

Implementado em `classifier._map_clusters_to_personas()`, traduz os clusters numéricos em rótulos de negócio por análise das médias intra-cluster (score de aderência, recência de visita, frequência de revisão, sensibilidade a desconto). Evita-se nomenclaturas genéricas como “Cluster

0".

4.4 Classificação (Base 2)

Algoritmo: **XGBoost** (multi:softprob, 300 estimadores, max_depth=6, learning_rate=0.08, eval_metric=mlogloss). Target: o cluster atribuído a cada cliente na Base 1, propagado para o registro pareado na Base 2. Split 80/20 estratificado, random_state=42.

5. Resultados do Classificador

Métrica	Valor
Accuracy	0.599
F1 macro	0.560
F1 weighted	0.589
Modelo	xgb-v1

5.1 Matriz de Confusão

	Pred abandono	Pred economico	Pred esquecido	Pred fiel
Real abandono	291	80	47	26
Real economico	103	145	36	22
Real esquecido	87	65	106	85
Real fiel	19	24	47	417

5.2 Leitura por classe

Perfil	Precisão	Recall	Suporte
Abandono	0.58	0.66	444
Economico	0.46	0.47	306
Esquecido	0.45	0.31	343
Fiel	0.76	0.82	507

Análise: a acurácia de 59.9% é coerente com a sobreposição intrínseca entre perfis comportamentais que compartilham faixa demográfica. O modelo é particularmente forte em identificar o perfil **Fiel** (alta precisão e recall) — exatamente o segmento mais valioso para o programa de fidelidade. Há confusão esperada entre **Esquecido** e **Econômico**, segmentos que podem ser tratados com ações parcialmente sobrepostas (lembretes + condições comerciais). Para o uso no chão da concessionária, a probabilidade de cada classe (e não só a top-1) é exibida ao vendedor, permitindo decisão informada.

5.bis Modelo em Produção — Dados Reais Ford BR

A versão de produção (xgb-real-v1) foi retreinada sobre **175.554** VINs reais do arquivo vin_share_Desafio_02.xlsx fornecido pela Ford. ETL em scripts/etl-d2-real.py converte XLSX → Parquet. reconstrói Base 1 (histórico completo) e Base 2 (features pré-compra: ano_modelo. ano_venda. mês_venda. dealer_venda. modelo. % histórico de cada perfil no dealer e no modelo). Implementação em services/ml/src/classifier_real.py.

Métrica	Valor
Accuracy	0.6270
F1 macro	0.4821
F1 weighted	0.6020
Treino / Teste	140.443 / 35.111
Modelo	xgb-real-v1

5.bis.1 Matriz de Confusão (dados reais)

	Pred abandono	Pred economico	Pred esquecido	Pred fiel
Real abandono	680	1.145	2.024	108
Real economico	477	2.036	2.330	383
Real esquecido	332	961	16.297	1.852
Real fiel	59	352	3.074	3.001

Distribuição observada na base real: ~55% Esquecido, ~19% Fiel, ~15% Econômico, ~11% Abandono. A predominância de Esquecido confirma a hipótese de que o maior ganho operacional está em reativar clientes que perdem o timing da revisão — exatamente o foco do módulo /leads, que ranqueia por risco de evasão.

5.ter Cobertura do Desafio 1 — Schema Canônico Ford D1

O Desafio 1 (Inteligência Competitiva) pede que o sistema permita comparações ponta-a-ponta com qualquer concorrente. A Ford forneceu um **template oficial de Vehicle Data com 262 atributos em 14 seções** (Wheels, Connectivity, Ice Line Up, Air conditioning, Safety, High tech, Global Closing, Trim, SunRoof, Seats, Lights, 4X4, Others + Motorização). Implementamos esse template como schema canônico no banco:

Objeto	Função
catalog_items	262 linhas read-mostly. Cada linha = 1 atributo do template (secao, ordem, nome, tipo: flag/numeric/text)
vehicle_catalog_values	Bridge (vehicle × item) com valor preenchido (X / 0 / numérico) + confiança + fonte
GET /competitive/catalog-items	Retorna os 262 atributos agrupados por seção
POST /competitive/compare/canonico	Retorna matriz 262 × N veículos para renderização da tabela fixa
/veiculos/comparar	UI exibe a tabela canônica colapsável por seção, com ícones ✓/X para flags e valores numéricos por trim

As três versões da Ford Ranger 26MY (XLT, Limited, Limited+) já chegam com todos os 262 valores preenchidos a partir do datasheet oficial. Cadastros de concorrentes (Hilux, Amarok, SW4, Frontier...) herdam o schema vazio e podem ser preenchidos manualmente ou via IA puxando do site oficial — habilitando comparação 1:1 estrita, como pede a Ford.

6. Estratégias de Retenção por Perfil

Codificadas em `classifier.ACOES_POR_PERFIL` e retornadas pelo endpoint `POST /predict` junto com o perfil predito — o CRM da concessionária pode disparar a ação automaticamente ou exibir para o vendedor:

Perfil	Ações sugeridas
Fiel	Convite ao programa de fidelidade premium • Oferta de upgrade no próximo modelo • Convites para eventos da marca.
Abandono	Contato proativo do consultor sênior em até 7 dias • Pacote de revisão com desconto agressivo (-30%) • Cashback na 1ª manutenção fora da garantia • Pesquisa qualitativa de motivo de saída.
Esquecido	Campanha SMS+WhatsApp lembrando próxima revisão • Bônus por trazer o carro nos próximos 30 dias • Oferta de busca/entrega domiciliar do veículo.
Econômico	Pacote de revisão com preço fechado • Programa de assinatura de manutenção (mensalidade baixa) • Cross-sell de peças genuínas com desconto progressivo.

7. Integração Operacional

O modelo é servido por uma FastAPI em `services/ml/src/main.py` (porta 8001). O API gateway Node consome em `POST /predict` a cada novo cadastro de cliente no portal Ford. O retorno (`perfil_predito`, `probabilidades`, `risco_evasao`, `recomendacoes_acao`) é gravado em `ai_predictions` e renderizado no card do cliente.

Privacidade: `/predict` recebe atributos de compra e perfil (dados pessoais), sem nome, CPF, e-mail ou telefone. `dealership_id` é pseudonimizado. A API assina corpo, timestamp e nonce; o serviço ML rejeita assinaturas expiradas e nonces repetidos no mesmo processo. Consulte `docs/SECURITY.md`.

8. Conclusão e Próximos Passos

A solução entrega uma resposta funcional e auditável para o problema de retenção: identifica perfis comportamentais reais a partir dos dados, prevê o perfil de novos clientes no ato da compra e sugere ações operacionais tangíveis para cada segmento.

Próximos passos sugeridos:

- Coletar dados reais adicionais de uma loja-piloto, com tracking de conversão pós-ação, para re-treino contínuo e validação operacional do modelo já em produção (xgb-real-v1, 175.554 VINs, accuracy 62,7%).
- Adicionar tracking de conversão das ações sugeridas (A/B) para fechar o loop modelo-ação-resultado e quantificar uplift de retenção por perfil.

- Treinar variantes específicas por região/dealership para capturar diferenças regionais de comportamento (preço-sensibilidade no Norte/Nordeste, etc.).
- Implementar drift detection mensal — re-treino automático quando distribuição das features mudar significativamente.

9. Entregáveis Técnicos

Item	Localização
Notebook EDA + treino	services/ml/notebooks/ford_segmentation.ipynb
Dados sintéticos (baseline)	services/ml/data/base1_full.parquet, base2_classifier.parquet
Dados reais Ford BR	services/ml/data/ford_real_base1_full.parquet, ford_real_base2_classifier.parquet
ETL D2 (XLSX → Parquet)	scripts/etl-d2-real.py
Modelo sintético	services/ml/models/classifier_base2.joblib
Modelo PRODUÇÃO (real)	services/ml/models/classifier_real_v1.joblib
Métricas (sintético)	services/ml/models/metrics.json
Métricas (real)	services/ml/models/metrics_real.json
Classifier real	services/ml/src/classifier_real.py
Serviço de inferência	services/ml/src/main.py (FastAPI)
Hybrid ML+IA classifier	apps/api/src/modules/retention/hybrid-classifier.ts
D1 Schema canônico (262)	services/ml/data/ford-d1-ranger-26my.json + migration 015
D1 Populate script	scripts/populate-catalog-canonical.mjs
Resumo Ford real	services/ml/data/ford-real-summary.json
Relatório (este doc)	docs/deliverables/Relatorio_Desafio_2_ML.pdf